華中科技大學

本科生毕业设计（论文）开题报告

题　　目: 基于多模态图检索增强的智能体工作流生成研究

院　　系　计算机科学与技术学院

专业班级　大数据 2201 班

姓　　名　詹熙至

学　　号　U202215549

指导教师　莫益军

2026 年 3 月 14 日

1 课题来源、目的及意义

1.1 课题来源

随着大规模语言模型的快速发展，智能体技术逐渐成为人工智能领域的重要研究方向。近年来，智能体系统从单模型问答逐步演化为具备任务分解、工具调用、协作规划等能力的复杂系统，形成了所谓的 Agentic AI[7]。与此同时，检索增强生成作为提升大模型知识利用能力的重要技术路线也在不断演进，从传统的向量检索逐步发展到结构化检索、图检索等更具表达能力的形式。

GraphRAG 作为一种基于图结构的检索增强方法，能够利用实体、关系等结构化信息为大模型提供更具逻辑性的上下文支持[1]。然而，现有 GraphRAG 主要面向文本知识图谱，对于图像、流程图、界面截图等多模态信息的处理能力有限[3]。

另一方面，智能体工作流生成是当前 Agentic AI 的核心能力之一。现有工作流生成方法大多依赖大模型的自然语言推理，缺乏结构化约束，容易出现步骤遗漏、逻辑跳跃等问题[11]。

因此，将多模态图谱构建、GraphRAG 检索增强与智能体工作流生成相结合，构建“多模态图检索增强的智能体工作流生成系统”，既符合当前学术界发展趋势，也具有工程应用价值。本课题需要完成任务书中提出的四项核心任务：综述基于图的智能体 RAG 分类、设计 GraphRAG 工作流生成框架、研究 GraphRAG 与智能体特征融合方法、实现完整系统原型。

1.2 课题目的及意义

本课题的研究目的主要包括以下三个方面：

（1）理论意义

本课题将系统梳理基于图的 RAG 技术体系[2]，分析其在智能体系统中的作用机制，提出多模态图谱与智能体特征融合的新方法。通过构建多模态图谱与 GraphRAG 检索增强机制，可以为智能体提供更具结构化的知识支持，推动 Agentic AI 在复杂任务规划方向的理论发展。

（2）技术意义

本课题将探索多模态图谱构建[15]、图检索增强[4]、智能体特征建模[10]、工作流生成[13]等关键技术，构建一个可运行的智能体工作流生成系统，提升智能体系统的稳定性、可解释性和可控性。

（3）应用意义

本课题具有广泛的应用前景，可应用于企业流程自动化、智能客服、运维故障排查等场景[8]，通过结构化知识与智能体规划能力的结合，提升系统的任务执行能力和用户体验。

2 国内外研究现况及发展趋势

2.1 GraphRAG 与图结构检索增强研究现状

传统 RAG 与基础版的 GraphRAG 主要依赖纯文本的向量匹配或语义图谱，难以捕捉非结构化视觉数据中的上下文拓扑特征[2]。相比之下，多模态 GraphRAG 将图像、图表等融入结构化图数据库，有效解决了跨模态对齐缺失与长链路推理易断层的痛点。

微软于 2024 年提出的基础版 GraphRAG 利用图社区摘要技术大幅提升了全局文本的推理能力，但其框架设计受限于单模态输入[1]。Abootorabi 等人[3]在 ACL 2025 发表的综述系统定义了多模态 RAG 的检索、融合与生成范式，明确指出跨模态图结构是突破多模态信息对齐瓶颈的关键路径。

针对长文档与复杂图表推理，Wan 等人[4]提出的 MMGraphRAG 框架通过 Image2Graph 技术构建了可解释的跨模态知识图谱，在 DocBench[14]和 MMLong-Bench 等多模态数据集上显著优于传统方法。在动态检索方面，Bu 等人[5]提出了基于查询语义动态构建局部知识图谱的机制，在 WebQA 和 MultimodalQA 数据集上实现了零样本推理的 SOTA 性能。

开源社区项目[6]探索了视频解析结合 Neo4j 图数据库的链路，实现了通过图查询语言精准召回视频关键帧与关联文本上下文。此外，工业界也在推动“多模态关联智能”架构的发展。

综上所述，多模态 GraphRAG 已成为弥合视觉理解与逻辑推理鸿沟的核心技术，但在如何将其检索得到的高质上下文无缝转化为智能体操作工作流方面，仍有大量学术空白亟待填补。

2.2 Agentic AI 与工作流生成研究现状

早期的智能体大多依赖单语言模型及硬编码的 Prompt，而当前的 Agentic AI 已演进为具备多模态感知、长效记忆和复杂工具调用能力的工作流编排系统[7]。

在智能体演进路径上，Zhou 等人[7] 系统论述了从 RAG 向 Agentic AI 演进的趋势，强调了结构化记忆网络对支撑智能体执行复杂任务的决定性作用。面向多模态环境交互，Xie 等人[8] 提出了 OSWorld，首个支持多模态智能体的真实操作系统评测基准。Ashraf 等人[9] 提出的 Agent-X 专门针对视觉智能体构建了深度多模态推理与工具调用基准。

在多模态工作流编排框架设计上，Zhang 等人[10] 提出的 OmAgent 是一种基于图结构编排引擎的多模态智能体架构，原生支持视觉语言模型与图状逻辑推理引擎。针对具体的业务工作流，Shi 等人[11] 利用知识库与多智能体协同进化机制，实现了 IT 故障排查工作流的自动化生成。Awad 等人[12] 提出的 Talk2Data 展示了如何在多模态对话中生成可验证的代码执行工作流。Wang 等人[13] 则探索了大型语言模型 Pipeline 的自动化编排。

总体而言，现有的多模态智能体在环境感知层已取得长足进步，但工作流的生成过程仍高度依赖模型自身的隐式推理，缺乏图谱级别的强制逻辑约束。

2.3 多模态图谱与智能体融合研究现状

多模态图谱构建是近年来的研究热点。CLIP、BLIP、InternVL 等多模态模型能够将图像与文本映射到统一空间，为多模态图谱构建提供了基础[15]。流程图解析技术也逐渐成熟，可用于提取流程节点与连接关系。

然而，多模态图谱在智能体系统中的应用仍处于起步阶段。现有研究主要集中在多模态问答、视觉 RAG 等方向，缺乏“多模态图谱 →GraphRAG→ 智能体工作流生成”的完整链路。本课题将探索多模态图谱构建、图检索增强与智能体

规划的融合机制，填补这一研究空白。

3 研究内容与技术方案

3.1 课题研究内容与预期目标

本课题的研究内容与预期目标旨在针对复杂设备故障排查与智能运维场景，提出并实现一套基于多模态 GraphRAG 的智能体工作流生成系统。具体而言，研究将首先解析包含文本手册、电路图、逻辑流程图及组件实物图片的多模态公开数据（如 DocBench[14] 、MultimodalQA 等子集），利用视觉语言模型与实体抽取技术，构建显式表达“现象—组件—排查步骤”连接关系的跨模态知识图谱。在此基础上，设计并实现查询驱动的多模态 GraphRAG 检索模块[5] ，通过图拓扑结构与高维向量双路召回，为大模型提供具备可解释性证据链的结构化上下文。随后，系统结合智能体特征图[10] ，通过多智能体协作机制完成复杂任务现象的拆解与路由规划[11] 。

最终预期目标是：构建出一个具备高可解释性的端到端系统原型，该系统能根据多模态输入，自动输出标准化、无逻辑跳跃且可直接执行的故障排查工作流（以 DAG 或 BPMN 图格式呈现），并在多模态长图文推理测试集上完成准确率与工作流可执行率的量化评估验证。

3.2 技术路线与方案

本课题的技术路线遵循“多模态数据结构化 → 跨模态图检索增强 → 智能体多步推理与编排”的自底向上设计思想，通过严密的分层解耦，实现从非结构化多媒体数据到可执行工作流的自动化转化。

首先，在多模态图谱构建层，采用“单模态特征提取与跨模态对齐”相结合的融合策略。系统将利用大语言模型语义分块解析纯文本手册，同时结合 CLIP 视觉编码器与 OCR 文档解析技术提取图像和流程图的关键特征，随后运用跨模态实体对齐算法，将文本实体与视觉对象映射为图数据库中的统一节点及关联边，沉淀为多模态知识图谱[15, 4] 。

其次，在 GraphRAG 检索增强层，实施“混合检索与子图推理”机制。面对用户的多模态查询指令，系统将其转化为图查询语言与稠密向量，在知识图谱中执行双路召回获取多跳相关子图；随后利用社区发现算法聚合局部图谱结构，生成过滤掉冗余噪声、具备严密逻辑关联链的结构化上下文提示[5, 1]。

最后，在智能体工作流生成层，依托基于大模型的规划智能体，系统将检索得到的高质上下文与内置的“智能体特征图”进行对齐[10]。通过引入 ReAct 或树搜索等高级推理框架，驱动智能体进行任务的逐层分解、角色动态调度与工具挂载，最终将多智能体的协作步骤序列化，组装并导出为 BPMN 或 DAG 格式的标准可执行工作流[11, 13]。

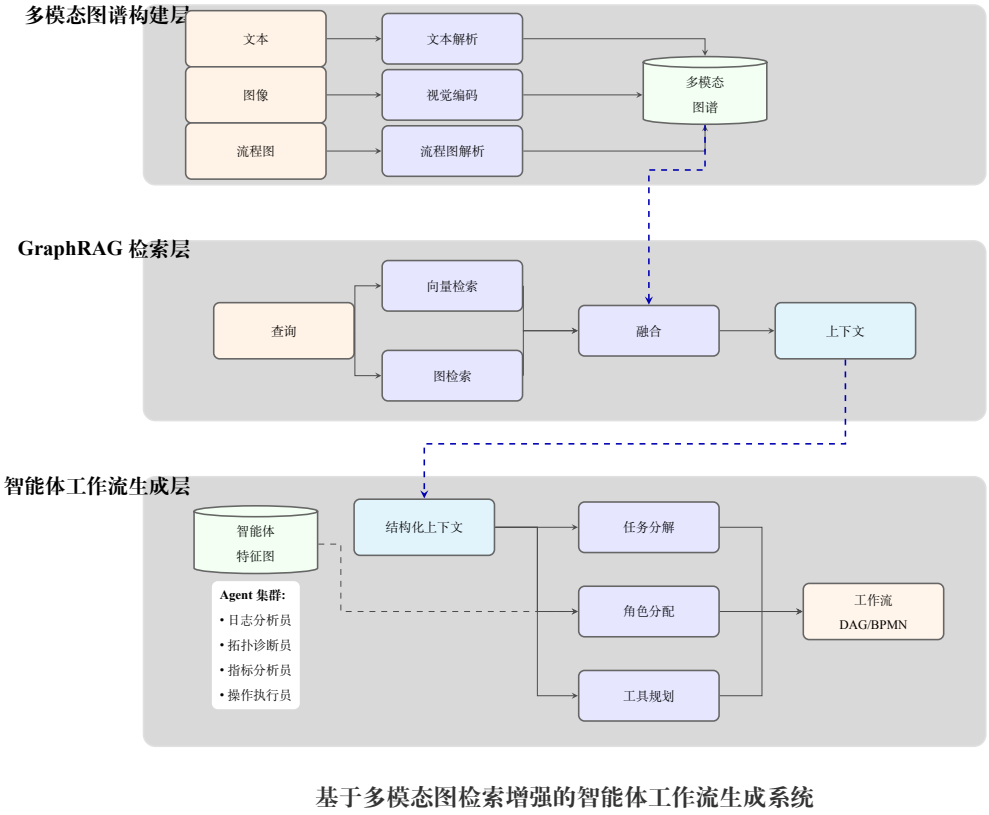

图 1　系统总体架构图

4　可行性与风险分析

4.1　制约因素与风险

（1）技术风险

- 多模态图谱构建复杂，实体识别和关系抽取的准确性直接影响检索效果
- GraphRAG 检索性能依赖图谱质量，若图谱覆盖不全可能导致检索结果偏差[4]
- 工作流生成可能出现逻辑不完整或步骤缺失[9]

（2）数据风险

- 多模态训练数据不足可能影响图谱构建效果[14]
- 图谱更新困难可能导致知识过时

（3）安全风险

- 需要身份认证与权限控制机制，防止未授权访问
- 需要设计验证机制防止模型幻觉导致错误工作流被执行

为降低风险，本课题将采用图结构约束工作流生成，引入验证智能体对生成结果进行检查，并设计用户确认机制确保关键步骤可控。

4.2 成本估算与可行性

本课题属于组织型软件项目，预计代码量约 4000–6000 行。采用 COCOMO 基本模型估算：

$$MM = 0.4 \times (KDSI)^{1.05} = 0.4 \times 5^{1.05} \approx 2.3\text{人月} \tag{4-1}$$

考虑到多模态图谱构建和模型调优的探索性工作，实际工作量预计为 3–5 人月，完全在毕业设计周期（5 个月）内可完成。结合风险分析，本课题具有较高可行性。

5 课题研究进度安排

根据任务书要求（2026 年 1 月 1 日 ~ 2026 年 5 月 30 日），本课题的进度安排如表1所示。

表 1　课题研究进度安排表

月份	工作任务
2026 年 1 月	阅读文献，完成开题报告，熟悉多模态图谱构建工具与 GraphRAG 相关技术
2026 年 2 月	构建多模态图谱原型，设计 GraphRAG 检索模块，完成初步实验
2026 年 3 月	实现智能体特征图构建与工作流生成模块，进行模块测试
2026 年 4 月	系统集成与实验评估，收集实验数据，分析系统性能，撰写论文初稿
2026 年 5 月	修改论文，完善系统，准备答辩

6　主要参考文献

[1] Microsoft Research. GraphRAG: A Graph-based Retrieval-Augmented Generation Framework. Microsoft Technical Report, 2024.

[2] Bommireddy R, Kancheepuram I, Akansha S. Graph-Based Agentic Retrieval-Augmented Generation: A Comprehensive Survey[J]. arXiv preprint arXiv:2412.08219, 2024.

[3] Abootorabi M M, et al. Ask in any modality: A comprehensive survey on multimodal retrieval-augmented generation[C]//Findings of the Association for Computational Linguistics: ACL 2025. Association for Computational Linguistics, 2025: 16776-16809.

[4] Wan X, Yu H. MMGraphRAG: Bridging vision and language with interpretable multimodal knowledge graphs[J]. arXiv preprint arXiv:2507.20804, 2025.

[5] Bu C, et al. Query-driven multimodal GraphRAG: Dynamic local knowledge graph construction for online reasoning[C]//Findings of the Association for Com-

putational Linguistics: ACL 2025. Association for Computational Linguistics, 2025.

[6] Multimodal-GraphRAG: Video understanding with graph database integration[CP/OL]. GitHub, 2024. https://github.com/example/multimodal-graphrag

[7] Zhou Y, Wang S. Towards the next generation of agent systems: From RAG to Agentic AI[J]. Proceedings of the VLDB Endowment, 2024, 17(12): 2150-8097.

[8] Xie T, et al. OSWorld: Benchmarking multimodal agents for open-ended tasks in real computer environments[C]//Advances in Neural Information Processing Systems 37. Curran Associates, 2024: 52040-52094.

[9] Ashraf T, et al. Agent-X: Evaluating deep multimodal reasoning in vision-centric agentic tasks[J]. arXiv preprint arXiv:2505.24876, 2025.

[10] Zhang L, et al. OmAgent: A multi-modal agent framework for complex video understanding with task divide-and-conquer[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2024.

[11] Shi B, Luo Y, Wang J, et al. FlowXpert: Expertizing troubleshooting workflow orchestration with knowledge base and multi-agent coevolution[C]//Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2. ACM, 2025: 4839-4850.

[12] Awad M N A, et al. A multimodal conversational agent for tabular data analysis[C]//2025 IEEE International Conference on Data Mining Workshops (ICDMW). IEEE, 2025.

[13] Wang J, Li G. AOP: Automated and interactive LLM pipeline orchestration for answering complex queries[C]//Proceedings of the 2025 Conference on Innovative Data Systems Research (CIDR). 2025.

[14] Zou A, et al. DocBench: A benchmark for evaluating LLM-based document reading systems[C]//Proceedings of the 4th International Workshop on Knowledge-Augmented Methods for Natural Language Processing. Association for Computational Linguistics, 2025.

[15] Liu J, Zhang H, et al. Multi-modal knowledge graph construction for Agentic AI[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2024.